



SISTEMA DE ANALISIS DE ACCIDENTES

ALEGRE VENTURA ROBERTO JHOSHUA)




COMPRENSIÓN DEL NEGOCIO

- Problema: altos índices de accidentes en en México
- Necesidad: rutas más seguras, no solo rápidas.

**18,932 ACCIDENTES
(2025)**

**+5000 ACCIDENTES EN
CARRETERAS (2023)**



OBJETIVOS DEL NEGOCIO



01.

Generar rutas que minimicen exposición a tramos peligrosos.


02.

Identificar zonas críticas para toma de decisiones.

03.

Localizar nuevos puntos óptimos para instalaciones médicas

DATA UNDERSTANDING



NUESTROS DATOS



HOSPITALES



CLUES



ACCIDENTES




VIALIDADES



2019-2023

LA DISTRIBUCIÓN GEOGRÁFICA DE ACCIDENTES Y HOSPITALES



INDICADORES DEL NEGOCIO NACIONAL

01


Reducción de distancia media al hospital

02


Severidad (heridos/muertos).

03

Cantidad de accidentes más cercanos



EL GRAFO DE VIALIDADES EN LA CDMX



INDICADORES DEL NEGOCIO CDMX

01

Tasa de accidentes por tramo.

02


Severidad (heridos/muertos).

03

Frecuencia temporal (hora, día, mes).




LIMPIEZA Y PREPROCESAMIENTO



Limpieza de datos

- Filtramos solo accidentes de CDMX, 2019–2023, con coordenadas presentes y sin duplicados, quedando ~78k registros a partir de 82,437.
- Normalizamos nombres de columnas y categorías (formato consistente en texto).
- Eliminamos registros sin coordenadas o sin hora/minutos y filtramos puntos fuera de un bounding box razonable de CDMX.
- Tratamos nulos:
 - Víctimas y vehículos → se imputan con 0.
 - Categorías clave sin valor → "DESCONOCIDO".
- Convertimos tipos (tiempo como enteros, coordenadas como float) para dejar un dataset limpio y coherente.
- ¿Y respecto a los outliers?




Bronze



Raw

Preprocesamiento (temporal, severidad y espacial)

- Consolidación temporal: limpiamos cada año (2019-2023) con la misma función y luego unimos todo en un solo dataset de accidentes.
- Variables temporales: construimos fechahora, dia_semana, es_fin_de_semana, es_hora_pico y una franja horaria (Madrugada, Mañana, Tarde, Noche).
- Severidad y gravedad:
 - Índice de severidad = $10 * \text{nemuerto} + 3 * \text{neherido}$.
 - Variable binaria de gravedad (grave / no grave).
 - Categorías LEVE, MODERADA, GRAVE, MUY_GRAVE y flags como hay_muertos, hay_heridos.
- Preprocesamiento espacial:
 - Convertimos los accidentes a GeoDataFrame y proyectamos a un sistema en metros.
 - Usamos un KDTree para asignar a cada accidente el tramo de calle más cercano, creando la tabla de accidentes con tramo y la base para calcular el riesgo histórico por tramo.




Silver



Validated


HOSPITALES



SELECCIÓN DE VARIABLES CLUES


Categoría	Variables / Descripción
Ubicación	- LATITUD - LONGITUD - geometry (puntos en EPSG:4326)
Contexto administrativo	- NOMBRE DE LA ENTIDAD - NOMBRE DEL MUNICIPIO - NOMBRE DE LA LOCALIDAD
Tipo de establecimiento	- NOMBRE TIPO ESTABLECIMIENTO (e.g., DE HOSPITALIZACIÓN, DE CONSULTA EXTERNA, DE APOYO) - NOMBRE TIPOLOGÍA (e.g., HOSPITAL GENERAL, HOSPITAL GENERAL DE ZONA, HOSPITAL INTEGRAL, UNIDAD MÉDICA RURAL)

DATOS GEOGRÁFICOS NACIONALES




OUTLIERS

(NIVEL NACIONAL)



MODELADO



MODELADO PREDICTIVO DE GRAVEDAD (ML)

Objetivo del modelado:

Predecir si un accidente será grave (1) o no grave (0) y generar un índice de riesgo ML a partir de ~20 variables seleccionadas (partimos de 60+ columnas).

SelectKBest, RFE con Random Forest e importancia de variables.

Decision Tree, Random Forest, Regresión Logística

MODELADO PREDICTIVO DE GRAVEDAD (ML)

Objetivo del modelado:

Predecir si un accidente será grave (1) o no grave (0) y generar un índice de riesgo ML a partir de ~20 variables seleccionadas (partimos de 60+ columnas).

SelectKBest, RFE con Random Forest e importancia de variables.

Decision Tree, Random Forest, Regresión Logística

Validación:

hicimos cross-validation 5-fold

El mejor modelo fue Random Forest con ~92% de accuracy y recall ≈ 0.97 para la clase grave, priorizando no dejar pasar accidentes graves.

MODELADO DE AGRUPACIÓN

Objetivo:

encontrar “puntos negros”: zonas donde los accidentes están muy concentrados.

Parámetros que usamos en DBSCAN :

- $\text{eps} = 200 \text{ m}$ (radio de vecindad).
- $\text{min_samples} = 20$ (mínimo de accidentes para formar un cluster).

**DBSCAN, Getis-Ord Gi,
Moran's I**


Resultados principales en DBSCAN:

- 299 clusters de accidentes.
- 17,178 accidentes dentro de clusters (53.4%).
- 14,961 accidentes aislados (ruido, 46.6%).

Moran's I = 0.6837 indica fuerte autocorrelación espacial positiva (los accidentes se agrupan en el espacio).

MODELADO DE AGRUPACIÓN

Mapa de Zonas Peligrosas - Top 50 (Datos Reales 2019-2023)



¿CÓMO DEFINIMOS UN ACCIDENTE GRAVE?

$$riesgo_{compuesto} = 0.6 \times riesgo_{histórico} + 0.1 \times riesgo_{cluster} + 0.3 \times riesgo_{ML}$$

60%

Riesgo Histórico

Accidentes pasados

10%

Clustering Espacial

Patrones DBSCAN

30%

Predicción ML

Random Forest

ALGORITMO DE IDENTIFICACIÓN DE HOSPITALES

1 Distancia al hospital más cercano con ball tree

2 Aplicar HDBSCAN para formar clusters

3 Filtrar por distancia y ponderar por muertos/heridos

4 Asignar hospitales a clusters desatendidos

5 Calcular centroides

$$w_i = 1 + 5 \cdot \text{TOTMUERTOS}_i + 2 \cdot \text{TOTHERIDOS}_i$$



¡MUCHAS GRACIAS!